

ОСНОВЫ КОМПЬЮТЕРНОЙ ЛИНГВИСТИКИ

ОСНОВЫ компьютерной лингвистики

- Языковедческие
- Математические
- Технические

NLP

Natural Language Processing

- техническая основа компьютерной лингвистики, обеспечивающая средства и методы компьютерного моделирования (анализа и синтеза) текстов (письменных и устных)
- на естественных языках.

NLP = NLG + ASR + NLU

- **ASR (Automatic Speech Recognition)** — технологии распознавания речи
- **NLU (Natural-language understanding)** - технологии понимания текстов (связных, осмысленных, произвольных)
- **NLG (Natural Language Generation)** - технологии генерации текстов на естественном языке

Проблемное поле NLP

- Синтез речи
- Распознавание речи
- Анализ текста
- Автогенерация текста
- Машинный перевод
- Диалоговые системы
- Информационный поиск
- Извлечение информации
- Распознавание текста
- Извлечение знаний
- Семантический поиск
- Автореферирование
- Автокорректурa
- Криптовалюты

Технические основы компьютерной лингвистики эволюция представлений о языковой машине

В языковой стихии

словѣне —
говорящие
«словами»
(по-нашему).

Племена
- *ѡзыкъи* -
(языки)



Вершина



Вильгельм фон Гумбольдт
(1767—1835)

Язык - живой дух, в
симбиозе с духовным
человечеством и
человеком.

Ветер перемен

Август Шлейхер

(1821-1868)

Язык - организм
природы.



От организма к механизму



Фердинанд Монжин
де Соссюр
(1857-1913)

...в языке нет ничего,
кроме различий

Граничные дефиниции языка

ЯЗЫК — живой дух, в симбиозе с духовным человечеством и человеком.

ЯЗЫК — это машина (множество всех подмножеств определенных над некоторым конечным множеством)

Языковедческие основы КЛ

- Язык – это машина
(лингвистический компьютер)
- Человек – биологический
компьютер (компьютерная
метафора)

Не всегда

- $2 + 2 = 4$
- Сумма углов в треугольнике 180°
- Параллельные прямые не пересекаются

Колмогоров Андрей Николаевич



- Период элементарной математики
VI век до Р.Х. - XVII век
- Период высшей математики XVII-XVIII века
- Период современной математики XIX—XX века

И. Ньютон и Г.В. Лейбниц



1643-1727



1646-1716

Георг Кантор



- 1845-1918
- немецкий математик,
- создатель теории множеств
- автор «бесконечности бесконечностей»
- изобретатель трансфинитных чисел....

Николя Бурбаки



Henri Cartan



André Weil



René de Possel



Charles Ehresmann



Laurent Schwartz



Jean Dieudonné



Claude Chevalley



Pierre Samuel



Jean-Pierre Serre



Adrien Douady

Слово и дело Бурбаки

Цель : написание серии книг, отражающих современное состояние математики

- Расцвет 1950—1960-е года.
- Последний выпуск - глава 10 «Коммутативной алгебры», 1998.
- До учебников дело не дошло...

Юрий Манин

Бурбаки – это было не обоснование математики, это была **выработка единого языка математики**, на котором могли разговаривать вероятностник, тополог, специалист по теории графов, логик.



Семиотическое

- **Текст** - объединенная смысловой связью последовательность знаковых единиц любой формы коммуникаций (письмо, песня, танец, рисунок, обряд).
- **Культура** - предел текста (в эру Культуры)
- Предел текста в современную эру – **техносфера**

Техника

Техника - инобытие (внешняя проекция) тела человека и тела человечества.

Техногенез (эволюция техники) - это процесс возникновения и совершенствования элементов техногенной реальности, превращение техники в самостоятельную силу, развивающуюся по собственным законам в направлении техносферы.

Техносфера

- **Техноценоз** - локальная совокупность технических систем в их отношениях между собой и с нетехническими факторами среды...
- **Техносфера** - системная целостность объектов, имеющих искусственное происхождение, все части которой связаны структурными взаимодействиями с обменом веществом, энергией и информацией.

Текстуальность

термин постструктурализма, констатирующий, что **внетекстовой реальности не существует** и любой индивид неизбежно находится внутри текста, мир есть бесконечный, безграничный текст (general text), в котором каждый текст всегда отсылает только к тексту.

Текст не есть событие, рождающееся внутри языка, но сам язык вписан в текст.

Метафоры (модели) понимания

- Человек, как очевидный самому себе индивид (целостный), весь мир объяснял самоочевидной метафорой человека
- Человек, потерявший свою идентичность и не верящий очам своим, себя самого пытается объяснить через непонятную ему метафору компьютера (составной машины)

Язык как машина

- Rule-Based 1950 — 1970-е
- Statistical-Based 1980 — 1990-е
- Probabilistic-Based 2000 — 2010-е

Больше чем машина

- Stochastic-Based 2022 – СЕЙЧАС

Rule-Based

- Просто, ясно и ... иногда верно))
- Имеет историческое значение
- Актуальны для школьного образования и ряда других задач
- Небо со дна колодца для ТЛ

Frederick Jelinek (1932-2010)



Пионер синтеза и
распознавания речи в NLP.
С 1959 года в США
MIT, Гарвард, Корнеллский
ун-те, IBM (применения
цепей Маркова для
распознавания речи)...

Frederick Jelinek (1932-2010)



- Anytime a linguist leaves the group the recognition rate goes up
- Каждый раз, когда лингвист покидает коллектив, качество распознавания речи возрастает.

В русском языке

- Не шесть падежей
- Не три временные формы глагола
- Есть артикли))

Grammar nazi

Абсолютизация
нормативного
подхода
к языку



Где поставить ударение?

Робот сначала обращается

- к составленным вручную словарям
- к правилам из академических справочников
- статистическим правилам.

ЗВОНИТ ИЛИ ЗВОНИТ

Ударение «звОнит»:

- лингвистами воспринимается спокойно,
- соответствует законам языка,
- не одобряется «**большинством образованных носителей**», поэтому нормативным пока не признаётся.

Как будет дальше? Посмотрим.

Было время...

«платИт», «курИт», «объявИт», «красИт»

у глагола «звонИть» происходит переход ударения в личной форме с окончания на корень

корень басИт бесИт бузИт бурИт винИт водИт
вопИт вялИт гноИт губИт дымИт душИт

Владимир Маркович Пахомов

- главный редактор **Грамота.ру**,
кандидат филолог-х наук

Основатель проекта

Алексей Кормилицын
(1961-2013).

Грамота.ру на 997 месте по
популярности в России



Логика и фанатизм

Владимир Пахомов (главный редактор справочно-информационного портала «Грамота.ру»):

- логика и законы языка подсказывают: кофе должно быть среднего рода.
- Несклоняемые неодушевлённые иноязычные слова, оканчивающиеся на гласный, в подавляющем большинстве случаев относятся к среднему роду

Логика и фанатизм

Владимир Пахомов

В 1920-х гг. можно прочитать

- «Открылся новый кино» (кинотеатр).
- «В пролёты улиц вас умчал авто».
- «Метро сверкнул перилами дубовыми».

Почему кто-то считает, что, если слово кофе станет среднего рода, это нанесет какой-то вред языку?

В чем суть да дело?

- Суть не замене одних правил другими (с делением слов на слоги и выбором ударной гласной ...)
- Суть в том, что неправильна сама абсолютизация языковых правил (каких бы то ни было)

Подобное - подобным

Rule-Based соответствует
классной-урочной системе
Яна Амоса Коменского, которая
великолепно отработала 500 лет
и больше не может и не должна

Филипп Меланхтон



- 1497—1560
- немецкий гуманист,
- теолог и педагог,
евангелический
реформатор, сподвижник
Мартина Лютера..
- автор «**Loci communes**»
(Общие принципы)

Ян Амос Коменский

- 1592-1670
- гусит (богемский брат),
- основоположник научной педагогики,
- систематизатор классно-урочной системы.
- автор «**Pansophiae Christianae**» (панглоссия)



Нельзя

- Научиться читать прогуливаясь и разговаривая о чтении
- Научиться работать с компьютером читая книги
- Нельзя научиться промптингу в правиловой (классно-урочной) системе

Гимназисты и лицеисты

- Гимнасий – упражняющийся обнаженным ...
- Лицей – Афинский гимнасий
- Перипатетики – ученики Аристотеля (те, кто прогуливаются возле Ликейя, рассуждая и обучаясь)

Античность ++

- Эпоха Древней Греции
и Древнего Рима
от 2 тысячелетие до РХ
- до завоевания Рима (5 век от РХ)

1445 - 2025 от PX



Ясно как солнце

- Обучение работы с инновационными глобальными стохастическими системами должно быть нелокальным и стохастическим, а не привычным, понятным и никак не соответствующим предмету обучения.

Statistical-Based

- Rule-Based 1950 — 1970-e
- **Statistical-Based** 1980 — 1990-e
- Probabilistic-Based 2000 — 2010e
- Stochastic-Based 2022 – СЕЙЧАС

СТАТИСТИКА НА ВСЕ РЕМЕНА



Статистический учёт
вёлся и в Древнем
мире.

В науку термин
«статистика» ввел
немецкий ученый
Готфрид Ахенваль в
1746 году

ПРИКЛАДНАЯ СТАТИСТИКА

- Числовая и нечисловая.
- Числовые статистические данные — это числа, вектора, функции. Их можно складывать, умножать на коэффициенты. Математический аппарат анализа сумм случайных элементов выборки — это (классические) законы больших чисел и центральные предельные теоремы.

ТОГДА И ТЕПЕРЬ

- **1899 год** Статистический метод в языкознании применялся и применяется довольно редко, что объясняется сравнительно незначительными результатами, полученными до сих пор при его помощи.
- **2022 год** **Квантитативный анализ** широко применяется к единицам любого уровня. Основным объектом является текст

СТАТИСТИЧЕСКИЕ МОДЕЛИ

- Статистические модели изначально были линейны.
- Разработка численных алгоритмов и рост вычислительной мощности компьютеров позволили перейти к нелинейным моделям.
- Существует разнообразное статистическое программное обеспечение общего и специализированного назначения.

Селегей Владимир Павлович



директор по
лингвистическим
исследованиям АВВУУ;
зав. кафедрами
"Компьютерной
лингвистики" в РГГУ и
МФТИ; председатель
Оргкомитета «Диалог».

Селегей Владимир Павлович

- В лингвистике нельзя обойтись одной лингвистикой...
- На современном этапе компьютерная лингвистика преимущественно основывается не на лингвистических, а на статистических подходах

Frequency Dictionary

Частотный словарь:

- список элементов (слов), вместе с информацией об их частотности (в тексте, языке, корпусе).
- элементы множества (слов) упорядоченные в соответствии с некоторой статистической величиной (обычно,

Frequency Dictionary

Частотный словарь - основа любых статистических методов и моделей NLP

Bag of words

Простейшая статистическая модель NLP –
«**мешок слов**»:

- учитывается только количество вхождений конкретных слов в тексте
- игнорируются все прочие характеристики:
 - порядок слов в документе,
 - морфологические формы слов,
 -

Bag of words

Простейший (?) элемент модели

Bag of words — слово с единственным атрибутом, частотой встречаемости этого слова в тексте (корпусе текстов).

Bag of words является мощным эффективным инструментом (в умелых руках, конечно)

Таямнічае «што» да «як»...



Японские пословицы



Русские пословицы



... с частотной лексикой

14.10.2015 г. в РУДН
представлены словари с
наиболее частотной лексикой
для мигрантов по истории и
законодательству России:
таджикский, узбекский,
киргизский, молдавский,
китайский, вьетнамский,
корейский и турецкий.



Костомаров Виталий Григорьевич

рос. лингвист, д.ф.н., профессор
президент АПН СССР, директор НМЦ
русского языка МГУ, инициатор
создания и ректор гос. института
русского языка им. А. С. Пушкина.
Президент Международной
ассоциации преподавателей русского
языка и литературы.
Главный ред. журнала «Русская речь»



Костомаров Виталий Григорьевич

- Идея учебного словаря, по-настоящему она была сформулирована именно у нас в Институте.
- Мы впервые посмотрели на словарь как на словарь обучающий, и поэтому получилось, что, например, англо-русских словарей может быть несколько.

Костомаров Виталий Григорьевич

- Раньше частотные словари создавались только в научных целях, а мы впервые подвели его под рамки учебного.
- Поэтому у нас такой словарь стал сопрягаться с идеей минимизации состава словаря.
- Например, был выпущен словарь под названием «Минимумы русской лексики».

Солнце Любовь Мама

Я возьму с собой в дорогу
Десять тысяч лучших слов....

Ольга Коваль

- Собираем в дорогу 100 слов
- Пишем ровно 100 слов
- Без знаков пунктуации
- Без ошибок
- На русском языке

Лингвистика и Big Data

- Лингвистика больших данных – квантитативная (статистическая, вероятностная, стохастическая)
- Компьютерная лингвистика – лингвистика больших данных (на 90%).

Время Big Data

Большие данные это данные, которые:

- огромны
- многообразны
- взаимосвязаны
- стремительно растут
- быстро меняются

Большие данные

- Big Data не о данных
- Big Data о выживании
в **пост**информационном обществе
- Big Data о новой «компьютерной»
парадигме мышления

Лексикон человека

- Два года - 200 слов
- Три года - 1000 слов
- Четыре года – 1500 слов
- Пять лет – 2200 слов
- Выпускника средней школы - 4000
- Выпускник вуза - 8000-12 000 слов.

Лексикон гениев

- В "Словаре языка **А.С. Пушкина**" в 4-х томах (М., 1956-1961)
21 191 слово.
- В произведениях **Вильяма Шекспира**
29 066 лексем.
- В текстах **Иоганна Вольфганга Гёте**
17 000 слов.

Urban Dictionary



UD - 7 500 000 вокабул

Oxford ED - 600 000 вокабул.

Global Language Monitor -
1,5 млн

Английский язык -
филологический диалект
Urban Dictionary?

Aaron Peckham

Вся жизнь в колыбели

- Основа традиционной лингвистики (небо со дна колодца)
- Имеет историческое значение
- Актуальны для школьного образования и ряда других задач



Циолковский
Константин Эдуардович
(1857-1935)

Земля —
колыбель
человечества,
но нельзя вечно
жить в колыбели

Путешествие
в окружающие миры
животных и людей

Теория значения



Якоб фон Икскуль

Ad Marginem

Выход из колыбели

Умвелт человека —
колыбель науки,
но нельзя вечно
жить в колыбели



из колыбели

Rule-Based —
колыбель
лингвистики,
но нельзя вечно
жить в колыбели

Векторная модель текста

Модель текста «мешок слов» является векторной моделью.

Векторная модель (vector space model) — представление текстов векторами из одного общего для всей коллекции текстов векторного пространства.

Например: частотный словарь текста...

Кортеж и вектор

- Кортеж — упорядоченный конечный набор длины n (где $n \in \mathbb{N} \cup \{0\}$), каждый из элементов которого f_i принадлежит некоторому множеству F .
- Вектор — кортеж однородных элементов (скаляров).
- Элементы кортежа называются его компонентами, или координатами.

Кортеж и вектор

- Совокупность векторов образует векторное пространство V над линейным пространством (полем) F .
- Перечень свойств вектора моделирует принятое в теории систем определение класса и состояния объекта.
- Изучаются векторным исчислением ...

Векторная модель текста

Векторная модель - основа решения задач:

- информационного поиска,
- атрибуции текста,
- статистического перевода,
- классификация документов,
- распознавания образов,
- кластеризации документов и др...

Латентно-семантический анализ

Модель "мешок слов" используется в LSA

LSA – обработка вербальной информации, устанавливающая взаимосвязь между текстами (документами) на естественном языке и терминами в них встречающимися.

Stochastic-Based



Stochastic-Based

